



时空同一性:多元时间序列预测的一个简单而有效的基线

Zezhi 邵

赵张飞王 3

北京计算技术研究所,

中国科学院[shaozezhi19b,zhangzhao2021, 王
飞]@ict.ac.cn

魏魏

华中科技大学

wangfei@ict.ac.cn

Yongjun 徐

上海计算技术研究所,

中国科学院

xyj@ict.ac.cn

摘要

多元时间序列(Multivariate Time Series, MTS)预测具有广泛的应用前景。最近,时空图神经网络(stgnn)由于其最先进的性能而成为越来越受欢迎的 MTS 预测方法。然而,最近的工作变得越来越复杂,性能提升有限。这种现象促使我们探索 MTS 预测的关键因素,并设计一个与 stgnn 一样强大,但更简洁高效的模型。本文将样本在空间和时间维度上的不可区分性视为关键瓶颈,并提出了一种简单有效的 MTS 预测基线,该基线通过附加时空身份信息(STID)来实现,该基线在简单多层感知器(mlp)的基础上同时实现了最佳性能和效率。这些结果表明,我们可以设计出高效有效的模型,只要它们能解决样本的不可区分性,而不局限于 stgnn。

CCS 的概念

• 信息系统→数据挖掘。

关键字

多变量时间序列预测, 基线, 时空图神经网络

ACM 参考格式:

邵泽智, 张钊, 王飞, 魏伟, 徐永军. 2022. 时空同一性:一个简单而有效的多元时间序列预测基线. 第 31 届 ACM 信息与知识管理国际会议论文集(CIKM' 22), 2022 年 10 月 17-21 日, 亚特兰大, GA, USA. ACM, USA, 纽约, 5 页. <https://doi.org/10.1145/3511808.3557702>

1 介绍

多元时间序列(Multivariate time series, MTS)数据是一种典型的时空数据,它包含多个相互关联的时间序列。准确、高效的 MTS 预报在许多应用中起着至关重要的作用。

邵泽智也在中国科学院大学工作。

王飞通讯作者。



本文授权使用 Creative Commons Attribution International 4.0 许可协议。

CIKM 22, 2022 年 10 月 17 日至 21 日, GA, USA
亚特兰大©2022 版权归所有者/作者所有。ACM
isbn 978-1-4503-9236-5/22/10。
<https://doi.org/10.1145/3511808.3557702>

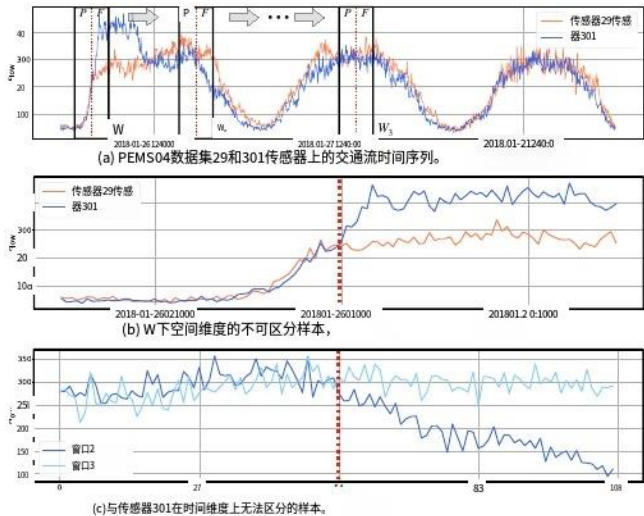


图 1:交通 MTS 数据示例及时空维度上的不可分辨样本。

从交通、能源到经济学[5,10,19],一直是学术界和工业界经久不衰的研究课题。

以往对 MTS 预测的研究通常分为两大类,即统计方法和基于深度学习的方法。前者假设变量(即时间序列)之间存在线性相关性。关于后者,早期的工作 b[9]利用卷积神经网络(CNN)来捕获变量之间的相关性,但忽略了它们的非欧几里得成对依赖关系。最近,时空图神经网络(stgnn)[14,15,18]因其最先进的性能而受到越来越多的关注。stgnn 结合了图卷积网络(GCN b[8])和序列模型[3,21]。前者处理变量之间的非欧几里得依赖关系,后者捕获时间模式。许多研究人员坚持不懈地努力设计强大的图卷积[2,20,22],或减少对预定义图结构的依赖[11,13,17]。尽管取得了重大进展,但最近基于 stgnn 的方法正在变得复杂,改进有限,这促使我们思考:我们能否改进 MTS 预测的关键因素,并设计一个与 stgnn 一样强大但更简洁高效的模型?为了回答上述问题,本文首先将样本在空间和时间维度上的不可区分性识别为一个关键瓶颈。随后,我们设计了一个简单而有效的基线模型来缓解这一瓶颈。

为了直观地说明我们的观察结果,我们以图 1 中的 MTS 数据为例,其中每个时间序列都来自一个交通流传感器。首先,如图 1(a)所示,样本由一个大小为 $P+F$ 的滑动窗口生成,其中 P 和 F 分别表示历史数据和未来数据的长度。例如, W_1 、 W_2 、 W_3 是三个不同时间的窗口。此外,考虑到不同的变量和时期具有不同的模式,我们可以预期生成许多具有相似的历史数据但不同的未来数据的样本。例如,图 1(b)显示了在窗口 W_1 下来自不同变量(即传感器 29 和 301)的样本,其中历史数据(左)非常相似,而未来数据(右)则不同。同样,不同时期(即 windows W_2 和 W_3)下来自 sensor 301 的样本如图 1(c)所示。简单的回归模型(例如,MLPs)无法根据它们相似的历史数据预测它们不同的未来数据,也就是说,它们无法区分这些样本。因此,我们将图 1(b)和图 1(c)中两类样本对背后的特征称为样本在空间和时间维度上的不可区分性。此外,最近的一项研究也表明, stggn 成功的关键因素是 GCN 减轻了空间不可区分性。

为了缓解上述瓶颈,我们设计了一个简单而有效的 MTS 预测基线模型,命名为 STID,该模型基于附加时空身份信息的直观思想。如图 2 所示,STID 利用一个空间嵌入矩阵 $E \in \mathbb{R}^{N \times D}$,以及两个时间嵌入矩阵 $T_{TiD} \in \mathbb{R}^{d \times D}$ 和 $T_{DiW} \in \mathbb{R}^{w \times D}$ 来表示空间和时间身份。 N 是变量的数量(即时间序列), N_{dis} 一天中的时隙数量(由采样频率决定), $N_w = 7$ 是一周中的天数, D 是隐藏维度。随后,STID 基于简单的 MLP 层对信息进行编码,并通过回归层进行预测。与基于 stggn 的方法相比,STID 具有更简洁的架构,大量实验表明,STID 比基于 stggn 的方法更强大,具有显著的效率优势。这些结果表明,我们可以通过解决样本的不可区分性来设计更高效和有效的模型,而不仅仅局限于 stggn。

2 预表

Definition 1. 多变量时间序列预测。多元时间序列可以表示为一个张量 $X \in \mathbb{R}^{T \times N}$,其中 T 为时隙数, N 为变量数。给定过去 P 时间段的历史信号 $X \in \mathbb{R}^{P \times N}$,多元时间序列预测的目的是预测 F nearest 未来时间段 $Y \in \mathbb{R}^{F \times N}$ 的值。我们额外表示来自时间序列 i at 时间步长 t as $X_{i:t-P:t} \in \mathbb{R}^P$ and $Y_{i:t:t+F} \in \mathbb{R}^F$ 的样本。

定义 2. 空间和时间身份。假设一天 w 中有一个时间序列和 dN time 槽位,一周中有 7 天的时间序列,则将其时空身份保存在三个嵌入矩阵中,即 $E \in \mathbb{R}^{N \times D}$, $T_{TiD} \in \mathbb{R}^{d \times D}$, $T_{DiW} \in \mathbb{R}^{w \times D}$,它们是可训练的参数, D 是隐藏维度。

3 模型架构

如图 2 所示,STID 由一个嵌入层、多个 MLP 层和一个回归层组成。为简单起见,我们用 $FC(\cdot)$ 表示

表 1:数据集统计。

数据集	长度#变体		采样率	时间跨度
PEMS04	16992	307	5分钟	2个月
PEMS07	28224	883	5分钟	3个月
PEMS08	17856	170	5分钟	2个月
PEMS-BAY电	52116	325	5分钟	6个月
力	2208	336	60分钟	3个月

作为全连接层。嵌入层变换原始历史时间序列 $X_{i:t-P:t} \in \mathbb{R}^P$ into 潜空间 $H_{i:t} \in \mathbb{R}^D$ by:

$$H_{i:t}^i = FC_{embedding}(X_{i:t-P:t}^i), \tag{1}$$

其中 D 是隐藏维度。然后,STID 通过以下方式附加时空身份 E_{ϵ} 、 T_{TiD} 和 T_{DiW} :

$$Z_t^i = H_t^i \parallel E_i \parallel T_{TiD}^{TiD} \parallel T_{DiW}^{DiW}, \tag{2}$$

以及其中 temporal $Z_{it} \in \mathbb{R}^{identities}$ 。4D 善意地表示隐藏的注意,表示空间和与时间空间身份是随机初始化的可训练参数,并且时间身份在时间槽中共享一天中的相同时间和一周中的同一天。随后,我们利用 L 层的 MLP 与残余连接来编码信息。 l -th MLP 层可表示为:

$$(Z_t^i)^{l+1} = FC_2^l(\sigma(FC_1^l((Z_t^i)^l))) + (Z_t^i)^l. \tag{3}$$

最后,回归层根据 $(Z_{it})^L$ 进行预测:

$$\hat{Y}_{t:t+F}^i = FC_{regression}((Z_t^i)^L), \tag{4}$$

在哪里 $(Z_{it})^L \in \mathbb{R}^{4D}$, $Y_{i:t:t+F} \in \mathbb{R}^F$ 的预测。^F 我们使用平均绝对误差(MAE)作为我们的损失函数:

$$\mathcal{L}(\hat{Y}, Y) = \frac{1}{NF} \sum_{i=1}^N \sum_{j=1}^F |\hat{Y}_{i,j}^i - Y_{i,j}^i|. \tag{5}$$

我们通过反向传播和梯度下降最小化 \mathcal{L} 来优化所有空间和时间身份和全连接层的参数。我们选择 Adam[7]作为我们的优化器。

4 实验

4.1 实验设置

数据集。根据前人的研究[5,17,18],我们对 PEMS04、PEMS07、PEMS08、PEMS-BAY 和 Electricity 这五种常用的多变量时间序列数据集进行了实验。统计信息汇总在表 1 中。值得注意的是,PEMS04、PEMS07、PEMS08 和 PEMS-BAY 数据集都带有一个预定义的图来表示时间序列之间的依赖关系。由于篇幅限制,我们没有详细介绍每个数据集。

基线。我们选择了大量具有官方公开代码的基线,包括传统方法 (VAR [12], HI[4])和典型的深度学习方法(LSTM [6], DCRNN [10], STGCN [20], Graph WaveNet [18], AGCRN [1], StemGNN[2]),以及最近的作品(GMAN [22], MTGNN [17], ST-Norm[5])。由于篇幅限制,我们没有对每种方法进行详细介绍。

指标。我们通过三种常用的多变量时间序列预测指标来评估所有基线的性能,包括平均绝对误差(MAE)、均方根误差(RMSE)和平均绝对百分比误差(MAPE)。



图 2:建议的 STID 概述。

实现。该模型在 NVIDIA RTX 2080Ti GPU 上使用 Py- torch 1.9.1 实现。将隐藏维度Dis 设置为 32。MLP 层数Lis 设置为 3。对于 PEMS04、PEMS07、PEMS08 和 PEMS-BAY 数据集，我们将历史数据的长度设置为Pto 12。对于电力数据集，我们设置P= 168。对于所有数据集，我们将未来数据F的长度设置为 12。学习率设置为 0.001。代码可在 <https://github.com/zezhishao/STID> 上获得。

4.2 性能研究

为了进行公平的比较，我们遵循之前工作中的数据集划分。PEMS- BAY 数据集的训练集、验证集和测试集的比例是 7:1:2，而其他数据集的比例是 6:2:2。我们的目标是在所有数据集上预测未来长度为 12 的时间序列，即F= 12。结果如表 3 所示。我们比较了这些方法在第 3、第 6、第 12 个时隙的性能以及平均 12 个时隙的性能，分别显示在 @3、@6、@12 和 avg 列中。最好的结果用粗体突出显示，次好的结果用下划线标出。此外，DCRNN、STGCN、Graph WaveNet(即 GWNet)和 GMAN 依赖于预定义的图。因此，由于没有图结构，这些方法在电力数据集集中的结果是不可得的。如表所示，STID 在几乎所有数据集的所有视界中都能获得最佳性能，并且不需要预先定义图形。这些显著的结果证明了 STID 的有效性。

4.3 效率研究

在这一部分中，我们比较了基于所有数据集的 STID 学习方法与其他学习方法的效率。为了更直观和有效的比较，我们比较了这些模型的每个 epoch 所需的平均训练时间。所有型号均在 Intel(R) Xeon(R) Gold 5217 CPU @ 3.00GHz, 128G RAM 计算服务器上进行训练，配备 NVIDIA RTX 2080Ti 显卡。

结果如表 2 所示。之前基于 stgcn 的模型的计算复杂度通常会随着输入时间序列的长度和变量的数量线性或二次增长。与其他数据集相比，PEMS07 数据集具有更多的变量(operation = 883)，Electricity 数据集具有更长的历史数据(operation = 168)。因此，以前的工作在 PEMS07 和电力数据集上花费了更多的时间。由于没有 GCN 和顺序模型(例如 RNN)的简洁架构，STID 在所有数据集上实现了一致的最佳效率。

4.4 消融研究

在这一部分，我们进行了消融研究，以验证时空身份的有效性。我们设置了 STID 的三种变体。STID

表 2:效率研究。

数据集	PEMS04	PEMS07	PEMS08系列	PEMS-湾	电
方法	秒/时代				
哪里	14.73	189.37	7.65	57.11	29.62
LSTM系列	7.78	25.73	4.56	28.34	22.26
DCRNN公司	95.12	510.53	57.17	351.35	- / a
STGCN	41.16	198.13	25.31	155.68	- / a
GWNet的	27.88	170.61	29.72	111.95	- / a
AGCRN公司	28.49	189.50	19.29	102.09	144.17
StemGNN	16.29	136.31	9.41	63.791	56.24
GMAN公司	107.31	827.77	71.04	410.67	N/A
MTGNN公司	25.11	107.03	79.45	90.18	28.59
STNorm	18.20	74.12	32.45	64.36	155.86
STID	5.24	14.32	4.46	15.76	2.31

w/o E 消除了空间特性。STID w/oTTiD 去除 TTiD 的时间同一性，而 STID w/oTDiW 去除 TDiW 的时间同一性。我们在 PEMS04 数据集上进行实验，并报告所有指标的平均值列。结果如图 3 所示。总之，所有这些身份都是有益的。其中最重要的是空间一致性，这意味着空间不可区分性作为 MTS 预测的一个主要瓶颈。此外，时间标识 TTiD 和 TDiW 也很重要，因为现实世界中的数据通常包含每日和每周的周期性。




图 3:PEMS04 数据集的消融研究。

4.5 可视化

为了进一步直观地理解和评估我们的模型，在本节中，我们将学习到的空间和时间特性可视化。具体地说，我们在 PEMS08 数据集上可视化 $E \in \mathbb{R}^N \times D$ ， $TTiD \in \mathbb{R}$ 抛掷 $d \times D$ ，和 $TDiW \in \mathbb{R}$ 抛掷 $w \times D$ of STID，其中，抛掷= 170，抛掷d= 288，抛掷w= 7。这里我们使用 t-SNE[16]来可视化 E 和 TTiD。对于 $TDiW \in \mathbb{R}$ 抛掷 $w \times D$ ，其中抛掷w= 7D=32，我们通过将 TDiW 的嵌入大小设置为 2 来训练 STID，以获得更准确的可视化效果。结果如图 4 所示。

表 3:对 PEMS04、PEMS07、PEMS08、pemsbay 和 Electricity 数据集的多变量时间序列预测。

电学方法	PEMS04系列								PEMS07								PEMS08系列								PEMS-湾							
	平均 MAE	@3	@6	@12	Avg.	@3	@6	@12	Avg.	@3	@6	@12	Avg.	@3	@6	@12	Avg.	@3	@6	@12	Avg.	@3	@6	@12	Avg.	@3	@6	@12	Avg.	@3	@6	@12
958 TC 3 HI	42.33	42.35	4237	42.36	4	4903	49	9	3457	51	50.43	5	5043	705	7.05	7.03	7	92.44	92.58	9279												
70.43 年	29.90%	29.92%	29.96%	29.92%	22.73%	22.75%	22.79%	22.75%	21.60%	21.63%	21.68%	21.63%	6.85%	6.84%	6.83%	6.84%	70.16	70.46	70.91													
229 其中	214	2372	2676	2351	3202	35.18	38.37	36	19.52	22.25	26.17	2207	1.74	232	293	221	2769	28.19	29.34													
10.23% MAE	34.30	36.58	40.28	36.39	48.83	52.91	56.82	5573	2973	33.30	38.97	3307	3.16	425	4	4.12	56.06	5755	805													
16.42%	18.02%	20.94%	17.85%	18.30%	20.54%	22.04%	19.93%	12.54%	14.23%	17.32%	14.04%	3.60%	5.00%	6.50%	5.01%	75.53%	79.94%	86.62%														
2042 LSTM	21.37	23.72	26.76	23.81	20.42	23.18	28.73	23.54	17.38	21.22	30.69	21	205	2.20	237	2.18	18.57	20.68	23.79													
33.31	36.58	40.28	36.62	33.21	37.54	45.63	38.20	26.27	31.97%	43.96	32.10	4.19	455	4.96	4.47	48.86	48.96	56.44														
15.21%	18.02%	20.94%	18.12%	8.79%	9.80%	12.23%	9.96%	12.63%	17.32%	25.72%	17.47%	4.80%	5.20%	5.70%	5.04%	32.88%	37.21%	39.42%														
162 DCRNN RMSE	18.53	19.65	21.67	19.71	19.45	21.18	24.14	21.20	14.16	15.24	1770	15.26	131	167	199																	
2.80MPE	29.61	31.37	34.19	31.43	0	34.42	38.84	34.43	22.20	24.26	27.14	24.28	3	4.66	3.74																	
N/美	13.45	13.45	150	1354	8.00	9.16	102	9.06	9.87%	1042	11345	10.43%	2.73%	3.75%	4.73%	3.61%																
- STGCN rmse	18.74	194	21.12	1963	2	21.66	2416	2171	14.95	15.92	17.65	15.98	15	19	2.01	163																
以	2984	31.34	3353	3132	32.73	35.35	3948	3	2348	6	28.03	25.37	2.88%	3.83	456	373																
12	13.27%	14.22%	13.32%	8.68	9.16%	10.26%	9.25%	9.87%	1042	11345	10.43%	2.88%	3.85%	4.74%	3.69%																	
NA GWNet RMSE	18.00	18.96	20.53	18.97	18.69	20.26	22.79	20.25	13.72	14.67	16.15	14.67	1	31	195	1.58																
以	28.83	30.35	3254	30.32	30.69	33.37	3711	3332	2	20	25.95	2349	2.78	373	452	3.65																
13.64%	14.23%	15.41%	14.26%	8.02%	8.56%	9.73%	8.63%	8.80%	9.49%	10.74%	9.52%	2	3.66%	4.63%	3.52%																	
2388 AGCRN RMSE	18.52	19.45	20.64	1936	1931	20.70	2274	20.64	14.51	15.66	17.49	15.65	17	1.70	1.99	1.63	22.88	24.47	2724													
53.02 MAPE	29.79	31.45	33.31	31.28	31.68	34.52	37.94	34.39	22.87	25.00	27.93	24.99	2.93	3.89	4.64	3.78	41.33%	48.93%	52.57%													
以	12.31%	12.82%	13.74%	12.81%	8.18%	8.66%	9.71%	8.74%	9.34%	10.34%	11.72%	10.17%	2.95%	3.88%	4.72%	3.73%	41.33%	48.93%	52.57%													
22.89 StemGNN RMSE	19.48	21.40	24.90	21.61	19.74	22.07	26.20	22.23	14.49	15.84	18.10	15.91	14	1.93	2.57	192	2145	23.56	24.98													
46.21APE	30.74	3346	38.29	33.80	3232	36.16	4237	36.46	23.02	25.38	27.77	2544	2.95%	3.88%	4.72%	3.73%	41.09	46.95	51.97													
57.26%	15.85%	19.50%	16.10%	8.27%	9.20%	11.00%	9.20%	9.73%	10.78%	12.50	10.90%	3.08%	4.54%	6.55%	4.54%	57.12%	65.34%	62.81%														
在GMAN的情况下	18.27	1881	2001	189	19.25	20.33	2225	20.43	13.80	1462	157	1481	13	165	1.58																	
在GMAN上	2935	3085	312	3093	3120	33.30	360	3	2288	212	2647	24.19	2.92	381	438	3.75																
N/美	12.66%	13.25%	13.40%	13.21%	8.21%	8633%	9.48%	8.69%	9.41	9.57%	10.56%	9.69%	2.88%	3.71%	4.51%	3.69%																
MTGNN公司	18.05	1948	20.95	1950	1923	2083	20.95	20.94	1430	1525	1680	1531	13	167	1	160	1678	1843	209	1818												
在MTGNN上	30.13	32.02	34.66		31.15	33.93	38.10	303	2255	241	2696	2442	2.84	379	455	3.70	3691	42.62	4833	4204												
14.04%	13.32%	14.08%	14.96%	8.55%	9.30%	10.10%	10.56%	10.54%	10.90%	10.70%			2.80%	3.74%	4.57%	3.57%	48.16%	51.31%	56.25%	50.77%												
魔法半导体	18.96 RMSE	18.92	20.20		31.70	35.10	38.65	34.85	14.44	15.53	1720	1554	1	1	16	160	18.74	21.14	2	20.69												
以	29.70	31.12	32.91		8.26%	8.84%	9.60%	8.77%	22.68	25.07	27.86	25.01	288	3.83	452	3.71	40.86	4824	55.27	47.55												
12.69% MAE	12.28%	12.71%	13.43		8.26%	8.84%	9.60%	8.77%	9.32%	9.98%	11.30%	10.03%	2.82%	3.75%	4.62%	3.60%	32.66%	37.07%	42.63%	35.98%												
他	17.51	18.29	19.58		18.31	19.59	21.52	19.54	13.28	14.21	15.58	14.20	130	1.62	1.89	1.55	16.08	17.87	19.25	17.39												
2982 马	12.005	12.46%	13.38%	12.49%	7.72%	8.30%	9.15%	8.25%	2166	2357	25.89	2	2.73%	3.68%	4.47%	3.51%	31.95%	37.80%	40.26%	35.53%												




图 4:可视化学习到的空间和时间特性。

首先，图 4(a)显示了不同变量(即时间序列)的身份可能聚类。这符合运输系统的特点。例如，路网中附近的交通传感器往往共享相似的模式。其次，图 4(b)可视化了每天 288 个时隙的嵌入。很明显，PEMS08 数据集存在日周期性。而且，相邻的时间段往往具有相似的特性。最后，图 4(c)显示工作日的身份是相似的，而周末的身份是非常不同的。

5 的结论

在本文中，我们提出探索 MTS 预测的关键因素，以设计一个与 stgenn 一样强大但更简洁有效的模型。具体来说，我们将样本在空间和时间维度上的不可区分性识别为

一个关键的瓶颈。随后，我们提出了一个简单而有效的 MTS 预测基线，通过附加时空特征信息，即 STID。基于简单的网络，STID 实现了更高的效率和性能。这些结果表明，通过解决样本的不可区分性，我们可以更自由地设计模型，而不仅仅局限于 stgenn。

致谢

国家自然科学基金(批准号:61902376、61902382、61602197)和 CCF-AFSG 研究基金(批准号:61902382)资助。部分资助:RF20210005，部分资助:华中科技大学与平安财险联合实验室(HPL)资助。中国博士后科学基金批准号:2021M703273。

参考文献

[10]白蕾,姚丽娜,李灿,王贤智,王贤智。2020。用于流量预测的自适应图卷积循环网络。NeurIPS(2020)。

[10]曹德富,王贤智,段娟勇,张佳,朱霞,黄从瑞,童杰,徐碧雄,白英,童杰,等。2020。多变量时间序列预测的谱时序图神经网络。NeurIPS(2020)。

[3]Kyunghyun Cho, Bart van Merriënboer, Dzmitry Bahdanau, Yoshua Bengio. 2014。论神经机器翻译的性质:编码器-解码器方法。在 SSST@EMNLP。

[4]崔岳,谢建东、郑恺。2021。历史惯性:长序列时间序列预测中被忽视但强大的基线。第30届ACM国际信息与知识管理会议论文集, 2965-2969。

[5]邓金良,陈秀思,蒋仁和,宋璇, Ivor W. Tsang. 2021。ST-Norm:多变量时间序列预测的时空归一化。在 SIGKDD。

[6]Sepp Hochreiter 和 Jürgen Schmidhuber. 1997。长短期记忆。神经计算

[7]Diederik P Kingma 和 Jimmy Ba. 2015。Adam:随机Optimization。在ICLR的方法(海报)。

[8]Thomas N Kipf 和 Max Welling. 2016。图 convolutional networks. arXiv 半监督分类 arXiv 预印本:1609.02907

[9]赖国坤,常伟成,杨一鸣,刘汉晓。2018。用深度神经网络建模长短期时间模式。在第41届国际ACM SIGIR信息检索研究与发展会议上。

[10]李亚光, Rose Yu, Cyrus Shahabi, Liu Yan. 2018。扩散卷积循环神经网络:数据驱动 的流量预测。在ICLR。

[10]林浩哲,范玉顺,张佳,白英。2021。Rest:时空耦合预测的互反框架。在2021年网络大会上。

[12]郑路、周晨、吴京、姜浩、崔松月。2016。融合格兰杰因果关系和向量自回归的大规模无线局域网流量预测。Ksiütis 10,1(2016), 136-151。

尚超,陈杰,毕金波。2021。离散图结构学习 Forcasting Multiple Time Series. 的 arXiv 预印本 arXiv:2101.06861

[14]邵泽志,张昭,王飞,徐永军。2022。多元时间序列预测的预测增强时空图神经网络。arXiv 预印本 arXiv:2206.09113

[15]邵泽志、张昭、魏伟、王飞、徐永军、曹鑫、Christian S Jensen. 2022。解耦动态时空图神经网络 for Traffic Forecasting. arXiv 预印本 arXiv:2206.09112

[16]Laurens Van der Maaten 和 Geoffrey Hinton. 2008。用 t-SNE 可视化数据。机器学习研究杂志

[17]吴宗汉,潘世瑞,龙国栋,蒋靖,常晓军,张承琦。2020。串连点:基于图神经网络的多元时间序列预测。在 SIGKDD. 753 - 763。

[18]Z Wu, S Pan, G Long, J Jiang, C Zhang. 2019。深度时空图建模的图波网。在IJCAI。展出

[19]俞在民、孙业俊、朴永灿、姜瑜, 2021 年。基于多级上下文的数据轴 Transformer 的精确多元股票走势预测。第 27 届 ACM SIGKDD 知识发现与数据挖掘会议论文集, 2037-2045。

[20]Yu Bing, Yin Haoteng, and Zhanxing Zhu. 2018。时空图卷积网络:用于流量预测的深度学习框架。发表于第 27 届人工智能国际联合会议论文集。

[21]Fisher Yu 和 Vladlen Koltun. 2015。扩展 arXiv 的多尺度上下文聚合 convolutions. arXiv 预印本:1511.07122

[22]郑传攀,范晓亮,王成,齐建中。2020。Gman:用于流量预测的图多注意力网络。在AAAI。